uc3m | Universidad Carlos III de Madrid

Práctica Final
Propuesta de Tema

Inteligencia Artificial en las Organizaciones
Grado Ingeniería Informática (2026/27)

Grupo 14:

Sergio González Jiménez
Alfonso Gabriel Pineda Fernández
Daniel López-Antona Pesquera
Edgar Antero Sánchez Elizondo

Título	BEV-UrbanMap: Sistema de visión cenital para vehículos autónomos

Resumen

La conducción autónoma necesita percibir en un espacio métrico, pero los sistemas de percepción tradicionales trabajan en el plano de la imagen, donde las distancias no se corresponden con las reales y las oclusiones dificultan la toma de decisiones. La representación en vista de pájaro (BEV, Bird's-Eye View) resuelve este problema proyectando la información de todas las cámaras sobre un plano cenital común.

En este trabajo implementaremos desde cero la arquitectura Lift-Splat-Shoot (LSS), que a partir de seis cámaras de un vehículo genera un mapa cenital segmentado. La red estima para cada píxel una distribución de profundidad (Lift), proyecta las características sobre una rejilla BEV usando la calibración de las cámaras (Splat) y procesa esa rejilla con una red convolucional que segmenta vehículos y zona transitable. Por último, se haría una fase de planificación o elección de ruta con menor coste (Shoot).

El extractor de características de imagen partirá de una red preentrenada en ImageNet a la que se le aplicará Fine-Tuning, mientras que las capas Lift, Splat, Shoot

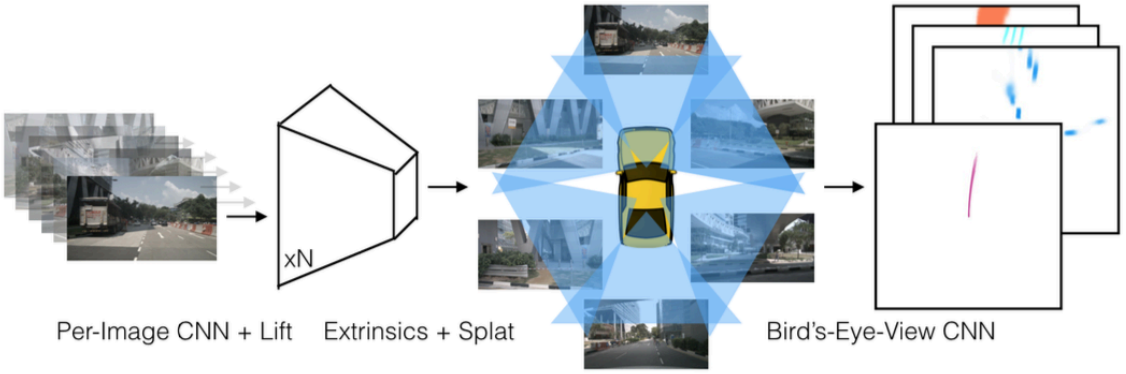
y el codificador BEV se programará y entrenará desde cero con el dataset nuScenes. El sistema evaluará el accuracy, además de la precision y recall, y el intersection over union (IoU).

Planteamiento técnico y viabilidad

a) Datos y recursos. Se utilizará el dataset nuScenes [1], que incluye seis cámaras con su calibración (intrínsecos y extrínsecos) y anotaciones 3D a partir de las cuales se generan las etiquetas BEV.

b) Técnicas de IA. Se implementará la arquitectura LSS [2], basada en redes neuronales convolucionales [4]:

- **Lift:** para cada píxel, la red predice una distribución categórica sobre un conjunto discreto de profundidades y un vector de contexto. Su producto exterior "eleva" la imagen 2D a una nube de puntos 3D en forma de tronco de pirámide (lo llaman *frustrum*)
- **Splat:** con los parámetros de calibración, los puntos de todas las cámaras se proyectan sobre una rejilla cenital común y se agregan mediante *sum pooling*, lo que produce una imagen BEV independiente del número de cámaras.
- **Shoot:** se proyectan trayectorias plantilla sobre un mapa de coste BEV para elegir la de menor coste.



c) Desarrollo previsto y reparto entre Fine-Tuning y desarrollo propio. Para trabajar con los datos usaremos el SDK de nuScenes y CARLA simulator en caso de que haya que añadir datos sintéticos. Luego usaremos el framework de PyTorch para desarrollar la arquitectura LSS, así como un backbone de Resnet50 o EfficientNet para la capa de Conv2D.

d) Evaluación. Para evaluar el modelo usaremos el accuracy, así como el precision y recall para identificar falsos positivos y falsos negativos. Además, calcularemos el intersection over union (IoU) para medir la calidad del modelo.

Bibliografía inicial

1. H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom, "nuScenes: A multimodal dataset for autonomous driving," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2020, pp. 11621–11631.
2. J. Philion and S. Fidler, "Lift, Splat, Shoot: Encoding images from arbitrary camera rigs by implicitly unprojecting to 3D," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2020, pp. 194–210.
3. T. Roddick and R. Cipolla, "Predicting semantic map representations from images using pyramid occupancy networks," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2020, pp. 11138–11147.
4. K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), 2016, pp. 770–778.
5. Z. Li, W. Wang, H. Li, E. Xie, C. Sima, T. Lu, Y. Qiao, and J. Dai, "BEVFormer: Learning bird's-eye-view representation from multi-camera images via spatiotemporal transformers," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2022, pp. 1–18.